TrIAderma

Daniel Pantoja Joaristi
Álvaro Arbona Rodríguez
Carlos Jabalquinto Hernán-Gómez
Zhixian Zhou
Marco Casteleiro Trigueros

Memoria del Sprint 3
En esta memoria se abarca todo lo relacionado con los sesgos en dermatología

October 25, 2026

Índice

1. Sesgos y problemas de accesibilidad en TrIAderma 3
   1.1. Sesgos en los datos de entrenamiento 3
   1.2. Brecha de uso en ancianos y discapacidad 3
2. Compromisos de Diseño 3
3. Métricas de Equidad y Requisitos 3
   3.1. Métricas clave de equidad 3
   3.2. Criterios mínimos para producción 4
4. Mapa de Usuarios y Poder 4
5. Riesgos y límites del proyecto 4
   5.1. Plausibilidad 4
   5.2. Líneas rojas 4
   5.3. Emergencias 4
   5.4. Rendición de cuentas 4
6. Anexo 5
   6.1. Formulas usadas 5
   6.2. Tablas 5
Bibliografía 6
Index of Figures 7

1. Sesgos y problemas de accesibilidad en TrIAderma

En dermatología, los datasets arrastran sesgos desde cualquier origen.

1.1. Sesgos en los datos de entrenamiento

Casi el 78% de los datos actuales provienen de hombres blancos de mediana edad [1]. Entrenar con esto sesga el modelo por **sexo, color de piel y edad**. Aunque en medicina se tiende a pecar de falsos positivos en caso de duda, el problema persiste. Además, la piel infantil y las patologías raras no suelen estar contempladas [2]. El **data augmentation** tampoco lo resuelve del todo; al no estar etiquetados el sexo, la edad ni el tono de piel, los nuevos datos generados heredan el mismo sesgo [1].

1.2. Brecha de uso en ancianos y discapacidad

Como vimos en el sprint anterior, las personas mayores o con condiciones como el daltonismo a menudo quedan desplazadas por interfaces no adaptadas.

2. Compromisos de Diseño

A partir de los sesgos identificados (etnia, género y edad) y las barreras de accesibilidad, se establecen los siguientes compromisos clave:

- **Equidad Étnica:** Mitigar errores en pieles oscuras evitando datos sintéticos básicos. Integrar datasets reales y diversos mediante el EHDS [3] e IIS para asegurar auditorías clínicas independientes del tono de piel.
- **Representación de Género:** Reequilibrar muestras ($\frac{50}{50}$) y etiquetar variables anatómicas para evitar subestaciones o sobreestimaciones de lesiones según sexo y zona corporal.
- **Inclusión de Tercera Edad:** Reducir la brecha digital con un **Modo Guiado** (asistencia por voz, UI simplificada) y garantizar la convivencia con la vía de atención presencial tradicional.
- **Protección y Gestión Infantil:** Permitir la gestión tutelada mediante la vinculación de cuentas de tutores legales y ajustar la ponderación diagnóstica a las particularidades morfológicas de la piel pediátrica.
- **Objetividad y Accesibilidad Universal:** Mantener la neutralidad clínica sin sesgos ideológicos y cumplir con estándares WCAG [4] (texto adaptable, lecturas alternativas) para personas con discapacidad.

3. Métricas de Equidad y Requisitos

Para cumplir con el **AI Act** (Art. 10) y la norma **ISO/IEC TR 24027:2021** [5], debemos garantizar que el modelo rinda de forma equitativa en todos los subgrupos de pacientes antes de salir al mercado.

3.1. Métricas clave de equidad

La **Demographic Parity** [6] busca que la probabilidad de diagnosticar una patología sea la misma para todos los grupos, como distintos rangos de edad o tonos de piel, sin tener en cuenta si el diagnóstico es correcto. Por su parte, la **Equalized Odds** exige mantener la misma tasa de aciertos (TPR) y de falsos positivos (FPR) Sección 6.1.

3.2. Criterios mínimos para producción

1. **Precisión clínica:** Sensibilidad $> 99\%$ en patologías críticas (melanomas o carcinomas) y especificidad $> 85\%$ en lesiones benignas.
2. **Resistencia a fallos visuales:** Degradación máxima del 5% en sensibilidad ante vello, desenfoque o variaciones de luz. Las máscaras de segmentación mantendrán un índice Dice ≥ 0.85 en lesiones ocluidas hasta un 25%.
3. **Triaje ágil (Vía Rápida Oncológica):** Tiempos máximos de respuesta según la gravedad, dando márgenes más pequeños a casos graves

4. Mapa de Usuarios y Poder

Médico de cabecera: Usuario principal. Valida las propuestas de la IA y gestiona el triaje, pero asume la responsabilidad clínica ante los errores del modelo.

Dermatólogo: Atiende casos graves priorizados. Ahorra tiempo en seguimiento, salvo que la IA sea demasiado conservadora y le sature la agenda.

Paciente digital: Envía datos y recibe atención remota. Es vulnerable al no poder auditar fácilmente el criterio de la IA ni del médico.

Colectivos vulnerables: El eslabón más débil. Sufren barreras de accesibilidad y el riesgo directo de sesgos algorítmicos en su prioridad de atención.

Hospital: Compra e integra el sistema. Busca eficiencia, pero debe fijar tiempos de consulta razonables para evitar que el médico confíe a ciegas en la IA.

5. Riesgos y límites del proyecto

Los riesgos encontrados se puede ver en la tabla de riesgos (Figura 1)

5.1. Plausibilidad

Las técnicas utilizadas son factibles con la tecnología actual, así que por eso no hay problema.

5.2. Líneas rojas

- La app nunca forzará al usuario a subir imágenes si este no lo desea.
- El modelo nunca dará un diagnóstico médico. Esto por ley está prohibido.
- El modelo solo podrá usarse con menores con supervisión paterna.
- El modelo nunca cederá datos de pacientes a terceros ni los usará para fines comerciales.

5.3. Emergencias

El sistema debería detenerse ante fallos de seguridad, filtraciones de datos, o ante comportamientos inusuales como caídas drásticas en la tasa de aciertos. Ante estas caídas se informaría a los usuarios y hospitales del motivo.

5.4. Rendición de cuentas

Implementamos un sistema de reclamaciones con tiempo de respuesta inicial de 7 días. Ante un desacuerdo con los resultados del modelo, se podría concertar desde una cita presencial con el dermatólogo hasta derivarlo a un comité médico. Contemplamos posibles compensaciones económicas en casos donde nuestro sistema haya perjudicado la salud del paciente.

6. Anexo

6.1. Formulas usadas

$$P\Big(\hat{Y} = 1 \mid A = a\Big) = P\Big(\hat{Y} = 1 \mid A = b\Big) \quad \forall a, b \tag{1}$$

$$P\Big(\hat{Y} = 1 \mid Y = y, A = a\Big) = P\Big(\hat{Y} = 1 \mid Y = y, A = b\Big) \quad \forall a, b, y \in \{0, 1\} \tag{2}$$

6.2. Tablas

Nombre del riesgo	Descripción	Gravedad (1-5)	Probabilidad (1-5)	Acciones de prevención	Acciones de contingencia
Filtración de datos	Brecha de seguridad que permita a atacantes acceder a los datos de los diversos pacientes.	5	3	Priorizar la codificación de los datos, y la seguridad de la aplicación.	Informar a las instituciones pertinentes, a los usuarios, y cerrar temporalmente la app y cualquier tipo de acceso.
Sesgo de color de piel	Falta de datos balanceados puede provocar peores resultados en ciertos tonos de piel.	2	4	Asegurar que los conjuntos de entrenamiento tienen una distribución de datos suficientemente equilibrada.	Seguir re-entrenando el modelo con datos más diversificados para intentar reducir el sesgo.
Falsos negativos	El modelo puede tener una alta tasa de falsos negativos (enfermedades reales clasificadas como que no lo son).	4	2	Entrenar y ajustar el modelo cuanto sea necesario para reducir esta tasa, y no desplegarlo hasta que tenga un valor suficientemente bajo.	Continuamente reentrenar el modelo con más datos de enfermedades para compensar el diagnóstico, y así reducir la probabilidad de fallo en el futuro.
Falsos positivos	Justo al revés que el riesgo anterior: enfermedades falsas clasificadas como reales. El riesgo de esto es que una alta tasa podría causar el mismo problema que intentamos evitar: la sobresaturación de centros médicos.	3	4	De nuevo, al igual que antes, ajustar el modelo para reducir esta tasa.	No es tan grave como pasar por alto enfermedades reales, por tanto una vez el paciente llegue a la cita médica, se verá que era una falsa alarma.
Uso indebido por menores	La app no debe ser usada por menores de edad sin supervisión de un adulto responsable a su cargo, debido a la sensibilidad de los datos que se usan.	5	2	Imponer algún tipo de control de edad. Ya que nuestro producto está enfocado a nivel nacional, podría enlazarse con la identificación fiscal del paciente.	Cortar el acceso/tumbar la cuenta, par evitar futuros usos de la misma.
Saturación por muchos accesos	El servidor hosteando el modelo puede no estar preparado para recibir un grand número de accesos simultáneos de golpe, colapsando el sistema.	2	1	Es una medida fácil de evitar, ya que conocemos el potencial riesgo, y por tanto podemos preparar el servidor para un alto número de peticiones a la vez, suficientemente alto ıon para evitar el colapso.	Desconectar temporalmente el sistema mientras nos ocupamos de aumentar la capacidad.
App inaccesible para colecivos	La app puede no estar preparada para ciertos colectivos, como gente con alguna discapacidad física, o personas de edad avanzada.	3	2	Seguir los patrones WCAG de diseño de interfaces.	Dar una forma accesible para poder pedir citas presenciales, o un tfno de contacto.
Cuentas no legítimas	Usuarios malévolos podrían dedicarse a crear cuentas falsas para saturar el sistema (DoS), o a cualquier otro tipo de actividad maliciosa.	2	1	A la hora de crear una cuenta nueva, solicitar algún tipo de identificación de manera que no pueda haber varias cuentas pertenecientes a un solo individuo.	Tumbar la cuenta de manera inmediata.

«Figura 1: Tabla de riesgos»

Bibliografía

[1] G. Kleinberg, M. J. Diaz, S. Batchu, y B. Lucke-Wold, «Racial underrepresentation in dermatological datasets leads to biased machine learning models and inequitable healthcare», *Journal of Biomedical Research*, vol. 3, n.º 1, pp. 42-47, 2022.

[2] F. Gröger *et al.*, «Biases in skin lesion dataset annotation and their impact on clinical model reliability», 2023.

[3] European Commission, «European Health Data Space Regulation (EHDS)». [En línea]. Disponible en: https://health.ec.europa.eu/ehealth-digital-health-and-care/european-health-data-space-regulation-ehds_es°

[4] World Wide Web Consortium (W3C), «Web Content Accessibility Guidelines (WCAG) 2 Overview». Accedido: 25 de octubre de 2026. [En línea]. Disponible en: https://www.w3.org/WAI/standards-guidelines/wcag/°

[5] International Organization for Standardization / International Electrotechnical Commission, «ISO/IEC TR 24027:2021 - Information technology — Artificial intelligence (AI) — Bias in AI systems and AI aided decision making», Geneva, Switzerland, Technical Report, 2021. [En línea]. Disponible en: https://cdn.standards.iteh.ai/samples/77607/c0664994eace4bd597db80bb10c18dec/ISO-IEC-TR-24027-2021.pdf°

[6] GeeksforGeeks, «Fairness Metrics: Demographic Parity and Equalized Odds». [En línea]. Disponible en: https://www.geeksforgeeks.org/artificial-intelligence/fairness-metrics-demographic-parity-equalized-odds/°

Index of Figures

Figura 1 5